

Bericht Maschinelles Lernen und Wissensbasierte Systeme

Zusammenfassung

Die Projektarbeit entwickelt einen webbasierten RAG-Chatbot als Assistenzsystem, das quellenbasierte, nachvollziehbare Antworten liefert und Halluzinationen möglichst reduziert. Im Mittelpunkt steht ein prototypischer Chatbot mit kuratierter Wissensbasis, modularer Architektur und Guardrails, der sich prinzipiell für den Einsatz auf einer Unternehmens-Website eignet, aktuell aber noch ohne vollständige organisatorische und rechtliche Einbettung bleibt.

Der Chatbot kombiniert Retrieval-Augmented-Generation, hybride Suche (lexikalisch und semantisch), ein tabellenorientiertes Produkt-Store-Konzept sowie spezialisierte Dialogflüsse für Bestellungen und Reklamationen, um strukturierte Prozesse in einen freien Chatkontext einzubetten. Ergänzend werden die aufgezeichneten Chats mittels Clustering und erste Gradient-Boosting-Modelle explorativ ausgewertet, um Nutzungsmuster sichtbar zu machen und Perspektiven für datengetriebene Prognosen im Produktkontext aufzuzeigen.

Die Evaluation zeigt, dass der Ansatz quellenbasierte Antworten und Halluzinationsreduktion grundsätzlich erreicht, die Leistungsfähigkeit jedoch stark von Datenqualität, Chunking-Strategie und robustem Retrieval abhängt. Insgesamt versteht sich die Arbeit als realitätsnahe Demonstration eines KI-gestützten Assistenzsystems, das technische, organisatorische und analytische Bausteine für eine spätere produktive Integration zusammenführt, ohne diesen Schritt bereits vollständig zu vollziehen.

Inhaltsverzeichnis

Zusammenfassung	1
Inhaltsverzeichnis	2
Einleitung	4
Ziele und Aufgabenstellung	5
Theorie	6
Methodik, Vorgehensweise und Prozeduren	6
Ergebnisse	9
RAG-Chatbot	9
Chunks	9
Reklamationen	9
Ansprechpartner	9
Bestellungen	10
Artikel	10
Clustering	12
Gradient Boosting	13
Datenqualität	13
Diskussion oder Interpretation	15
RAG-Chatbot und Halluzinationsreduktion	15
Chunking, Retrieval und Antwortqualität	15
Datenqualität, Produkt-Store und Ansprechpartner	15
Dialogflüsse, Reklamationen und Bestellungen	16
Clustering und Gradient Boosting	16
Einordnung im Kontext der Projektziele	16
Schlussfolgerungen	18
Bewertung des RAG-Chatbots	18
Einordnung im Projektkontext	18
Empfehlungen	19
Datenqualität	19
Empfehlung – Dialogflüsse und Usability	19
Empfehlung – Monitoring und Fehlermanagement	19

Empfehlung – Ausbau analytischer Komponenten	19
Semantisch auf Themen prüfen.....	19
Rank Fusion	20
Referenzen Biographie	22
Anhänge	24
Eigenständigkeitserklärung.....	27
Reproduzierbarkeit	27

Einleitung

Die im Rahmen dieser Projektarbeit entwickelte Webanwendung beschreibt die Konzeption und Umsetzung eines RAG-Chatbots, der fachlich korrekte, quellenbasierte Antworten liefert und Halluzinationen möglichst reduziert. Ziel ist ein Assistenzsystem, dessen Antworten konsequent auf einer kuratierten Wissensbasis beruhen und für Nutzerinnen und Nutzer transparent nachvollziehbar bleiben.

Aus heutiger Sicht ist eine direkte produktive Integration in die bestehende Unternehmens-Website nur begrenzt realistisch, da der Chatbot in dieser Arbeit als prototypische Lösung mit begrenzter Datenbasis und ohne vollständige organisatorische Einbettung umgesetzt wurde. Neben technischen Fragen wie Stabilität, Wartbarkeit und Monitoring betreffen die offenen Punkte auch rechtliche und betriebliche Aspekte, etwa den Umgang mit fehlerhaften Antworten, Supportprozessen oder der kontinuierlichen Pflege der Wissensbasis.

Der Fokus der Arbeit liegt daher auf einer realitätsnahen Demonstration von Architektur, Retrieval-Pipeline, Prompting-Strategien sowie exemplarischen Dialogflüssen für Bestellungen, Reklamationen und analytische Auswertungen und nicht auf einer bereits abgeschlossenen Live-Einführung. Die Umsetzung orientiert sich an einem Setup, das prinzipiell in eine Webumgebung überführt werden könnte, erfordert dafür aber zusätzliche technische, organisatorische und qualitative Absicherungen.

Für Test- und Demonstrationszwecke steht ein webbasiertes Interface zur Verfügung, über das die zentralen Funktionen des Systems erprobt werden können. Zusätzlich wird ein separater Chat-Bereich bereitgestellt, der direkt im Browser über den Pfad /manuel aufgerufen werden kann und ausschliesslich Fragen zu dieser Projektarbeit beantwortet, sodass Leserinnen und Leser den Inhalt interaktiv erkunden können.

Ziele und Aufgabenstellung

Die Projektarbeit verfolgt das Ziel, einen webbasierten RAG-Chatbot zu entwickeln, der fachlich korrekte, quellenbasierte Antworten liefert, Halluzinationen möglichst vermeidet und so gestaltet ist, dass er realistisch auf einer Webseite eingesetzt werden kann. Der Chatbot soll als verlässliches Assistenzsystem dienen, dessen Antworten konsequent auf der hinterlegten Wissensbasis beruhen und für Nutzerinnen und Nutzer nachvollziehbar und vertrauenswürdig sind.

Ursprünglich konzentrierte sich die Arbeit ausschliesslich auf die Konzeption, Implementierung und Evaluation dieses Chatbots, also auf Wissensbasis, Retrieval-Pipeline, Prompt-Strategien zur Halluzinationsreduktion sowie die technische Einbettung in eine Weboberfläche inklusive Sitzungsverwaltung und Logging. Erst in einem späteren Projektverlauf wurde der Umfang erweitert: Die aufgezeichneten Chats sollten nun zusätzlich mittels Clustering-Verfahren in thematisch ähnliche Gruppen segmentiert werden, um Nutzungsmuster und wiederkehrende Fragestellungen sichtbar zu machen, und darüber hinaus wurden mit Gradient-Boosting-Modellen erste explorative Vorhersagen im Produktkontext (z.B. mögliche Nachfrage- oder Interessentendenzen) entwickelt.

Aus dieser schrittweisen Erweiterung ergibt sich die Aufgabenstellung zweistufig: Zunächst ist ein RAG-Chatbot zu entwerfen und umzusetzen, der fachliche Fragen mit hoher Genauigkeit und geringem Halluzinationsrisiko beantwortet und in einer Webumgebung betrieben werden kann. In einem zweiten Schritt wird die bereits vorhandene Chat- und Produktdatenbasis genutzt, um nachgelagert Clustering und Gradient-Boosting-Modelle zu integrieren, die den Funktionsumfang der Anwendung um analytische Auswertungen und erste Prognosefunktionen erweitern, ohne das ursprüngliche Hauptziel – einen robusten, verlässlichen Chatbot – zu verändern.

Theorie

Dieses Projekt lässt sich als KI-basiertes Assistenzsystem verstehen, das Nutzereingaben verarbeitet, kontextbezogen reagiert und in Teilen prozesshaft handelt (z.B. Bestellung/Reklamation). Grundlegend ist dabei das Agentenkonzept: Ein System nimmt Informationen auf und wählt Handlungen, die ein Ziel bestmöglich unterstützen. Da Informationen unvollständig sein können und Ressourcen begrenzt sind, orientiert man sich an begrenzter Rationalität (bounded rationality) statt an „perfekter“ Optimalität. (Poole & Mackworth, 2023; Russell & Norvig, 2023)

Zur inhaltlichen Bearbeitung sind Wissensrepräsentation und Schlussfolgern zentral: KI-Systeme müssen Informationen so nutzen, dass daraus konsistente, nachvollziehbare Antworten entstehen. Klassische KI betont hierbei explizite Modelle/Regeln und Inferenz; praktisch relevant ist vor allem, dass ein System transparent mit Unsicherheit umgeht und fehlende Information durch Rückfragen oder Einschränkungen der Aussage abfedert. (Ertel, 2021; Poole & Mackworth, 2023; Russell & Norvig, 2023)

Dialoge können ausserdem als sequenzielle Problemlösung betrachtet werden: Der Systemzustand umfasst Kontext, offene Informationslücken und ein Ziel (z.B. „Antwort liefern“ oder „Fall abschliessen“). Das Vorgehen ähnelt Suche/Planung im Zustandsraum, bei der Rückfragen als zielgerichtete Schritte zur Vervollständigung der benötigten Angaben dienen. (Poole & Mackworth, 2023; Russell & Norvig, 2023)

Für Auswertung und Verbesserung eines Assistenzsystems sind Methoden des maschinellen Lernens relevant: Unüberwachtes Lernen (z.B. Clustering) hilft, wiederkehrende Themen in Nutzereingaben zu identifizieren; überwachte Verfahren (z.B. Regression) können Trends modellieren, sind aber stark von Datenmenge und Evaluation abhängig. (Ertel, 2021; Poole & Mackworth, 2023; Russell & Norvig, 2023)

Schliesslich betont die praxisorientierte Perspektive, dass KI-Systeme nicht nur technisch funktionieren sollen, sondern steuerbar, nachvollziehbar und organisatorisch verantwortlich sein müssen (Qualitätskriterien, Kontrolle, Umgang mit Risiken, Erwartungsmanagement). (Schmid et al., 2023)

Methodik, Vorgehensweise und Prozeduren

Die in diesem Projekt verwendete Methodik basiert auf der Konzeption und Implementierung eines serviceorientierten, retrieval-gestützten Assistenzsystems mit modularer Architektur. Der technische Kern besteht aus einem webbasierten Dienst auf Basis eines FastAPI-Backends mit statischem Frontend, einem öffentlichen Chat-Interface sowie einem administrativen Portal. Die Kommunikation erfolgt über klar getrennte Endpunkte für dialogorientierte Sitzungen (Chat) und reine Frage-Antwort-Interaktionen, wobei Sitzungen serverseitig verwaltet werden, um Kontexte und Zustände über mehrere Nutzereingaben hinweg zu erhalten.

Für Konfiguration und Initialisierung wird ein Factory-Ansatz genutzt, der sämtliche notwendigen Komponenten zur Laufzeit aus Umgebungsvariablen und Konfigurationsdateien aufbaut. Hierzu zählen insbesondere Indexe und Retriever für das Information-Retrieval, die Anbindung an ein Large Language Model, produktbezogene Datenspeicher sowie Repositories für Bestellungen und Reklamationen. Ergänzend wird ein zentrales Logging eingerichtet, um Anfragen, Systemzustände und Fehlersituationen systematisch zu erfassen und für spätere Analysen verfügbar zu machen.

Das Retrieval-Modul folgt einem Retrieval-Augmented-Generation-Paradigma und kombiniert dateibasiertes Indexing mit hybriden Suchverfahren. Textquellen in Form von TXT-, Markdown- und PDF-Dateien werden über einen eigenen Indexer in kleinere, überlappende Textsegmente (Chunks) zerlegt, um sowohl kontextuelle Konsistenz als auch feingranulare Suche zu ermöglichen. Die nachgelagerte Suche nutzt einen hybriden Ansatz aus lexikalischer Gewichtung (TF-IDF bzw. BM25-ähnliche Verfahren) und semantischen Embeddings auf Basis eines externen Embedding-Modells. Ein optionaler persistenter Vektorstore dient zur Speicherung von Embeddings und ermöglicht performante semantische Abfragen; bei Nichtverfügbarkeit greift das System auf den hybriden Standardretriever zurück. Zur Steigerung der Relevanz kommen Pfad- und Feld-basierte Boosting-Regeln sowie spezielle Priorisierung für Artikelnummern zum Einsatz. Ergänzend wird ein tabellenorientierter Produkt-Store aus CSV- und PDF-Quellen aufgebaut, der über heuristische Verfahren strukturierte Tabellenantworten für produktbezogene Anfragen generiert.

Die Generierung von Antworten erfolgt durch ein konfigurierbares Large Language Model (LLM) der Vertex-Plattform, das über dedizierte Systemprompts gesteuert wird. Innerhalb der Methodik werden unterschiedliche Prompt-Varianten für allgemeine Auskünfte, Reklamationsdialoge und emotional sensible Kontexte (Empathie-Hinweise) eingesetzt. Guardrail-Mechanismen schreiben die Verwendung expliziter Quellenangaben vor und erzwingen eine klare Trennung zwischen modellinternem Wissen und referenzierten Dokumenten. Zusätzlich werden Query-Expansion, Sprachidentifikation und automatische Übersetzung genutzt, um Nutzereingaben zu normalisieren und multilingual verarbeiten zu können.

Die dialogische Orchestrierung erfolgt über einen zentralen Controller, der eingehende Anfragen semantisch klassifiziert und an spezialisierte Teilflüsse weiterleitet. Dazu gehören ein reiner Frage-Antwort-Modus, ein Bestellfluss, ein Reklamationsfluss (RMA), ein vorgelagerter „Pre-Order“-Gate zur Unterscheidung von Kaufabsicht und Beratungswunsch sowie einfache Smalltalk- und Statusabfrage-Routinen. Der Bestellfluss verwendet ein Slot-Filling-Verfahren zur schrittweisen Erfassung aller notwendigen Kundendaten und Artikeldetails, inklusive Validierung und abschliessender Bestätigung vor der Persistierung. Der RMA-Fluss implementiert einen geführten Reklamationsdialog mit Abfrage relevanter Fakten, optionaler SLA-Information und anschließender Speicherung der Reklamationsfälle.

Die Datenhaltung ist in leichtgewichtige, dateibasierte und relationale Komponenten unterteilt. Bestellungen und Reklamationen werden als JSONL-Dateien abgelegt,

während Chats in einer relationalen Datenbank (SQLite) protokolliert und über Exportmechanismen in CSV-Form für nachgelagerte Auswertungen zugänglich gemacht werden. Produkt- und Vektordaten werden in dedizierten Verzeichnissen gehalten, um ein modular erweiterbares Datenlayout zu gewährleisten.

Für analytische Auswertungen kommen Verfahren des unüberwachten Lernens und der klassischen Textanalyse zum Einsatz. Nutzeranfragen werden mit TF-IDF-Vektorisierung (einschliesslich 1- und 2-Grammen) repräsentiert und mittels K-Means-Clusteranalyse in thematische Gruppen segmentiert. Die Wahl der Clusterzahl erfolgt heuristisch unter Nutzung des Silhouette-Koeffizienten und zusätzlicher Filter für Rauschen und Kleinstcluster. Diese Clusterungen werden im Admin-Portal zur Verfügung gestellt und dienen der Identifikation wiederkehrender Fragestellungen und Optimierungspotenziale. Darüber hinaus werden Log-, Dokument- und Produktdaten geladen, um Trends und Nutzungsmuster zu berechnen; hierzu kommen neben TF-IDF und K-Means auch einfache Prognosemodelle (z.B. Gradient-Boosting-Regressoren) für zeitliche Entwicklungen zum Einsatz. Das Admin-Frontend visualisiert Bestellungen, Chats, Cluster und weitere Kennzahlen in einer webbasierten Oberfläche mit periodischem Polling der Backend-Endpunkte.

Ergebnisse

RAG-Chatbot

Chunks

Im Rahmen der Evaluation der Chunking-Strategien diente die Standardkonfiguration mit einer Chunk-Grösse von 800 Tokens und einer Überlappung von 200 Tokens als Referenz für den produktiven Betrieb des RAG-Chatbots. Ergänzend wurde eine alternative Konfiguration mit 400 Tokens Chunk-Grösse und 100 Tokens Überlappung getestet, bei der sich in den beobachteten Sitzungen keine merklichen Unterschiede hinsichtlich Antwortqualität oder Latenz im Vergleich zur Standardkonfiguration zeigten.

Demgegenüber weisen die Sitzungen *748a6c92-97b41c51-056f-4ebe-b71b-0df72af11c7a* und *def32703-d527bc1c-590e-4783-b30d-7e461650f757*, in denen eine stark verkleinerte Chunk-Grösse von 80 Tokens bei 20 Tokens Überlappung verwendet wurde, eine deutlich geringere Antwortqualität und längere Antwortzeiten auf. Besonders in den letzten Interaktionen der Session *748a6c92-97b41c51-056f-4ebe-b71b-0df72af11c7a* lassen sich Verzögerungen und weniger treffende Antworten beobachten, sodass diese Konfiguration in den Ergebnissen als Beispiel für ein suboptimales Chunking herangezogen und gegenüber den stabileren Konfigurationen 800/200 und 400/100 kritisch diskutiert wird.

Reklamationen

In der Sitzung *22be6a26-47384cac-6d91-4370-b1ab-2b27dcbab8b8* wurde erstmals der Reklamationsprompt direkt in den Systemprompt integriert, wodurch das Modell deutlich näher an das gewünschte Antwortverhalten herangeführt werden konnte und Reklamationen fast so bearbeitete, wie es konzeptionell vorgesehen war. Zuvor wurden Reklamationen zunächst ohne spezialisierte Prompting-Strategie getestet; dabei zeigte das LLM zwar deeskalierende Tendenzen, übernahm jedoch vorschnell Schuld und generierte keine systematischen Rückfragen oder Folgefragen zur Fallklärung.

In einem weiteren Schritt wurde ein separater Reklamationsprompt eingeführt, der über schlüsselwortbasierte Trigger wie „Garantie“ oder „Defekt“ aktiviert wurde, was zu einem grundsätzlich verbesserten, aber nicht in allen Fällen konsistenten Verhalten führte, da alltagsnahe Formulierungen wie „kaputt“ nicht zuverlässig erfasst wurden. Aus diesen Beobachtungen ergaben sich zwei konzeptionelle Ansätze: Erstens eine semantische Klassifikation sämtlicher Eingaben hinsichtlich Reklamationsbezug oder zweitens die Integration des Reklamationsprompts in den globalen Systemprompt. Aufgrund des geringeren Implementierungsaufwands und der höheren Robustheit gegenüber variierenden Nutzerformulierungen, wurde die zweite Variante umgesetzt.

Ansprechpartner

In der Sitzung *653d1681-a3f07719-f971-4d88-9008-3230df62f47e* sollte der Chatbot für einzelne Kantone jeweils die zuständige Kontaktperson liefern, produzierte jedoch unzuverlässige und teilweise falsche Zuordnungen, was auf fehlerhafte oder

inkonsistente Einträge im zugrunde liegenden Vektorspeicher zurückzuführen ist. In der nachfolgenden Sitzung `5c127243-9e2a8529-1d66-4f75-81b0-8826d187dbca` verbesserte sich das Verhalten deutlich, nachdem der Vektorspeicher vollständig zurückgesetzt und auf Basis bereinigter, angepasster Datensätze neu aufgebaut worden war, sodass veraltete und fehlerhafte Repräsentationen entfernt wurden.

Ein konkretes Beispiel für die bereinigte Datenhaltung ist der Eintrag des Aussen-dienstmitarbeiters Reto Knaus, dessen Datensatz nun Name, zuständige Kantone (AI, AR, GL, GR, SG, TG mit ausgeschriebenen Kantonsnamen), Telefonnummer und E-Mail-Adresse in einem konsistenten Block enthält. Im ursprünglichen Setup waren dagegen nur Kantonskürzel im Hauptdatensatz hinterlegt, während die Zuordnung von Kürzel zu ausgeschriebenem Kantonsnamen in einer separaten Datei gepflegt wurde, was dazu führte, dass die semantische Verknüpfung zwischen Kürzel, Vollname und zuständiger Person im Retrieval-Prozess häufig scheiterte. Die Kombination aus Vektorstore-Reset und dieser nun konsistenteren, vollständigeren Repräsentation der Kontaktdaten verbessert die Datenqualität und ermöglicht präzisere kantonsspezifische Antworten des RAG-Chatbots.

Bestellungen

Der Bestellprozess ist als eigener Dialogfluss realisiert, der semantisch über die erkannte Kaufabsicht der Nutzenden ausgelöst wird und anschliessend einem festen, skriptbasierten Frage-Antwort-Schema mit Wahl- und Pflichtfeldern folgt. Am Beginn steht eine explizite Entscheidungsfrage:

*Möchten Sie direkt bestellen oder zuerst eine Beratung/Produktempfehlung?
Bitte antworten Sie mit bestellen oder Beratung.*

Antwortet die Nutzerin oder der Nutzer mit „Beratung“, wird die Konversation in den allgemeinen RAG-Chatbot zurückgeführt, während bei der Eingabe „bestellen“ – auch wenn das Wort isoliert eingegeben wird – der Bestell-Dialogfluss gestartet wird. In diesem werden die relevanten Bestelldaten strukturiert abgefragt, validiert und als Pflicht- bzw. optionale Felder erfasst, bevor die Bestellung final bestätigt und gespeichert wird.

Artikel

Zu Beginn wurden die Produktdaten aus dem technischen Katalog im PDF-Format eingebunden, das im Anhang auf Seite 24. Der tabellenorientierte Produkt-Store konnte dabei zwar die Artikelnummern und die erwarteten Massangaben erkennen, die einzelnen Dimensionen liessen sich jedoch nicht zuverlässig den richtigen Spalten zuordnen, sodass Ausgaben in der Form Artikelnummer / Mass 1 / Mass 2 / Mass 3 überwiegend nur Platzhalterwerte enthielten, etwa `61550573 / - / - / -`.

Um diese Einschränkung zu umgehen, wurden die betreffenden Artikeltabellen anschliessend in CSV-Form vorliegen, wie im Anhang auf Seite 25 gezeigt. In dieser Struktur konnten die Felder sauber geparkt und den entsprechenden Spalten im Produkt-Store zugeordnet werden, sodass der Chatbot für Anfragen zu Nutex-Plus-Sägen

nun korrekte Kombinationen aus Artikelnummer, Durchmesser, Schnittbreite und weiteren Parametern liefern kann.

Die Generierung der CSV-Dateien erfolgte nicht direkt aus der Weboberfläche des Herstellers, da erste Versuche mit einem separaten Python-Skript, die Tabellen automatisiert von der Website zu extrahieren, zu unzuverlässigen und unvollständigen Ergebnissen führten. Stattdessen wurden aufgrund der überschaubaren Artikelanzahl Screenshots der relevanten Tabellen erstellt und mit einem externen Tool (Codex) in strukturierte CSV-Dateien überführt, die anschliessend in den tabellenorientierten Produkt-Store des Chatbots integriert wurden.

Clustering

Die Clusteranalyse der Chatprotokolle hatte das Ziel, die unterschiedlichen Arten von Nutzeranfragen möglichst fein zu strukturieren und daraus konkrete Ansatzpunkte zur Verbesserung des Chatbots abzuleiten. Dazu wurden sämtliche verfügbaren Chats zunächst gesammelt, von technischen oder irrelevanten Einträgen bereinigt und in numerische Textrepräsentationen (Vektoren) überführt, bevor darauf ein Clustering-Verfahren angewendet wurde, das ähnliche Anfragen zu Gruppen zusammenfasst.

Im Ergebnis entstanden mehrere thematisch klar interpretierbare Cluster, die typische Nutzungsszenarien abbilden. Ein Teil der Cluster bündelt Fragen zu Personen und Funktionen im Unternehmen, etwa zur Geschäftsleitung oder zu bestimmten Ansprechpersonen, während ein anderer Teil Begrüssungen und kurze Einstiegsnachrichten enthält, die häufig den Beginn eines Chats markieren. Im Anhang auf Seite 26 ist noch ein Ausschnitt der Ergebnisse zu sehen. Weitere Cluster gruppieren Anfragen zur Terminvereinbarung mit dem Aussendienst (z.B. der Wunsch, dass jemand vorbeikommt und ein Problem vor Ort begutachtet) sowie Reklamationen, in denen Nutzerinnen und Nutzer Probleme mit gelieferten Produkten oder Bestellungen schildern.

Neben diesen gut sichtbar dominierenden Themenbereichen wurden zusätzliche, kleinere Cluster identifiziert, die speziellere oder seltener auftretende Anliegen umfassen, etwa Detailfragen zu einzelnen Produkten, Nachfragen zu Bestellstatus oder vereinzelte, kontextspezifische Sonderfälle. Insgesamt zeigt sich, dass sich die Chat-Anfragen in eine Reihe wiederkehrender Muster gliedern lassen, wodurch sowohl die Priorisierung von Verbesserungsmassnahmen (z.B. spezialisierte Prompts und Dialogflüsse für Reklamationen oder Terminwünsche) als auch die Identifikation von Themenlücken in Wissensbasis und Systemlogik deutlich erleichtert wird.

Gradient Boosting

Für die explorative Vorhersage von produktbezogenen Kennzahlen wurde ein Gradient-Boosting-Regressor implementiert, der auf den aus den Chat- und Produktdaten abgeleiteten Merkmalen trainiert werden sollte. Aufgrund der begrenzten Anzahl verfügbarer Beobachtungen war die resultierende Modellgüte jedoch nicht aussagekräftig, sodass keine belastbaren Schlussfolgerungen hinsichtlich Nachfrage- oder Interessensprognosen gezogen werden konnten; der entwickelte Codepfad ist funktionsfähig, erfordert für eine valide Evaluation aber eine deutlich grössere Datenbasis, deren Generierung den Rahmen dieser Arbeit überschritten hätte. (*A Guide to The Gradient Boosting Algorithm*, o. J.; *Forecasting with XGBoost and LightGBM - Skforecast Docs*, o. J.; *GradientBoostingRegressor*, o. J.)

Trotz der aus Datenmangel resultierenden Einschränkungen bleibt Gradient Boosting für diese Aufgabenstellung grundsätzlich eine geeignete Methode. Baumbasierte Gradient-Boosting-Modelle sind speziell für tabellarische Daten mit komplexen, nichtlinearen Zusammenhängen vorteilhaft, benötigen keine aufwendige Merkmals-Skalierung und können sowohl unterschiedliche Merkmalstypen als auch Interaktionen zwischen Variablen gut abbilden, was sie für Prognosen im Produkt- und Nutzungsverhalten grundsätzlich attraktiv macht. (*Forecasting with XGBoost and LightGBM - Skforecast Docs*, o. J.; *Gradient Boosting Algorithm in Machine Learning*, 2025; *What Is Gradient Boosting?*, 2025; Tunguz, 2025)

Datenqualität

Die Qualität der Prognosen steht und fällt mit der Qualität der zugrunde liegenden Daten. „Datenqualität“ umfasst dabei nicht nur das Vorhandensein vieler Datensätze, sondern vor allem Vollständigkeit, Konsistenz, Aktualität, Validität und Eindeutigkeit. Im Produktkontext treten typischerweise mehrere Probleme auf: Uneinheitliche Produkt-IDs über Systeme hinweg, fehlende oder unvollständige Produktattribute, unklare Definitionen von Kennzahlen (z. B. „Nachfrage“ = Views, Bestellungen oder Anfragen?) sowie Lücken in der zeitlichen Abdeckung. Gerade bei Long-Tail-Produkten sind Signale selten, wodurch die Daten stark „spärlich“ werden und Modelle leicht in Richtung der häufigsten Produkte/Kategorien verzerren.

Für Gradient Boosting ist Datenqualität besonders kritisch, weil das Verfahren sehr gut Muster lernt – auch falsche. Drei Fehlerklassen sind dabei häufig:

1. Rauschen und inkonsistente Labels: Wenn Zielgrößen wechselnd definiert, nachträglich korrigiert oder unvollständig erfasst werden, „sieht“ das Modell widersprüchliche Lernsignale. Das führt zu instabilen Modellen und stark schwankenden Feature-Importances.
2. Datenlecks (Leakage): Merkmale, die Informationen aus der Zukunft enthalten (z. B. nachträglich bekannte Retouren, spätere Statusfelder oder aggregierte Kennzahlen über einen Zeitraum, der den Prognosezeitpunkt überschneidet), erzeugen künstlich hohe Performance, die im Betrieb sofort zusammenbricht.

3. Zeitliche und strukturelle Verzerrungen: Kampagnen, Sortimentswechsel oder Preis-/Lieferkettenereignisse verändern die Datenverteilung. Ohne saubere zeitbasierte Evaluation lernt das Modell eher „Vergangenheit“ als generalisierbare Zusammenhänge.

Aus diesen Gründen reicht „mehr Daten“ allein nicht aus; entscheidend sind saubere Datenpipelines und klare Definitionen. Praktisch bedeutet das: eindeutige Schlüssel (Produkt, Zeitraum, Kanal), dokumentierte KPI-Definitionen, Deduplication-Regeln, plausibilisierte Wertebereiche (Outlier-Checks), konsistente Zeitzonen/Timestamps und ein trainierbarer Datensatz, der die spätere Nutzung realistisch abbildet (zeitbasierte Splits, keine Vermischung von Vergangenheit und Zukunft). Erst auf dieser Basis lässt sich Gradient Boosting sinnvoll als Prognosekomponente bewerten und – falls gewünscht – weiterentwickeln.

Diskussion oder Interpretation

RAG-Chatbot und Halluzinationsreduktion

Die Evaluation zeigt, dass der entwickelte RAG-Chatbot das zentrale Ziel, quellenbasierte, nachvollziehbare Antworten zu liefern und Halluzinationen zu reduzieren, grundsätzlich erreicht, zugleich aber deutlich von der Qualität und Konsistenz der zugrunde liegenden Wissensbasis abhängt. Insbesondere die Guardrails mit expliziter Quellenangabe und die strikte Trennung zwischen modellinternem Wissen und Dokumenteninformation tragen dazu bei, dass Antworten transparenter und für Nutzerinnen und Nutzer besser überprüfbar werden.

Gleichzeitig verdeutlichen einzelne Sitzungen, dass das System in Situationen mit unvollständigen oder widersprüchlichen Daten weiterhin zu unpräzisen oder gar falschen Aussagen tendiert, etwa bei anfänglich fehlerhaften Ansprechpartner-Zuordnungen. Die beobachteten Effekte machen deutlich, dass Halluzinationsreduktion nicht allein über Prompting und Retrieval, sondern vor allem über eine kuratierte, konsistente Datenbasis erreicht werden kann, was den prototypischen Charakter der Implementierung unterstreicht.

Chunking, Retrieval und Antwortqualität

Die Untersuchungen zu unterschiedlichen Chunking-Konfigurationen zeigen, dass eine zu starke Verkleinerung der Chunks zwar theoretisch eine feinere inhaltliche Auflösung erlaubt, praktisch jedoch zu längeren Antwortzeiten und weniger treffenden Antworten führt. Insbesondere die Sitzungen mit 80-Token-Chunks verdeutlichen, dass das Modell in solchen Fällen stärker fragmentierte Kontexte erhält und dadurch Schwierigkeiten hat, zusammenhängende, kohärente Antworten zu generieren.

Die stabilen Konfigurationen mit 800/200 bzw. 400/100 Tokens deuten darauf hin, dass für den gegebenen Anwendungsfall ein moderat grosser Chunk-Kontext vorteilhaft ist, weil er genügend Zusammenhänge abbildet und gleichzeitig performante Abfragen ermöglicht. Damit bestätigt sich die in der Theorie angedeutete Annahme, dass Retrieval-Systeme stets einen Kompromiss zwischen Kontexttiefe, Granularität und Effizienz eingehen müssen, der domänenspezifisch kalibriert werden sollte.

Datenqualität, Produkt-Store und Ansprechpartner

Die Probleme im Ansprechpartner-Szenario machen deutlich, dass selbst ein technisch korrekt implementiertes RAG-System durch inkonsistente oder unvollständige Datenschemata massiv in seiner Nützlichkeit eingeschränkt wird. Erst durch den vollständigen Neuaufbau des Vektorstores auf Basis bereinigter, konsistenter Datensätze mit einheitlicher Repräsentation von Kantonskürzeln und -namen konnten zuverlässig korrekte Antworten erzeugt werden.

Ein ähnliches Bild zeigt sich beim tabellenorientierten Produkt-Store: Die anfängliche Nutzung von PDF-Tabellen führte dazu, dass wichtige Dimensionen nicht sauber

extrahiert werden konnten und der Chatbot nur Platzhalterwerte ausgab. Die manuelle Transformation in CSV-Strukturen mit klar definierten Spalten ordnete Artikelnummern und Masse hingegen zuverlässig zu, wodurch der Chatbot nun korrekte und für Nutzende direkt nutzbare Produkttabellen liefern kann; dies illustriert, wie stark der praktische Nutzen eines RAG-Systems an saubere Datenmodellierung gebunden ist.

Dialogflüsse, Reklamationen und Bestellungen

Die iterative Entwicklung des Reklamationsprompts zeigt, dass spezialisierte Prompt-Strategien für sensible oder komplexe Anwendungsfälle unverzichtbar sind, um ein konsistentes, fachlich angemessenes Verhalten zu erreichen. Während frühe Varianten zu vorschnellen Schuldbekennnissen ohne strukturierte Fallaufnahme führten, ermöglicht die Integration des Reklamationsprompts in den globalen Systemprompt eine robustere, deeskalierende und informationsorientierte Bearbeitung von Reklamationen.

Der Bestellfluss demonstriert, dass sich klassische dialogische Konzepte wie Slot-Filling erfolgreich mit LLM-basierter Generierung kombinieren lassen, um strukturierte Prozesse wie Bestellungen in einen freien Chatkontext einzubetten. Gleichzeitig wird sichtbar, dass solche prozessualen Abläufe klare Zustandsverwaltung, Validierung und Bestätigung erfordern, um Fehlbestellungen zu vermeiden, Anforderungen, die über reine Textgenerierung hinausgehen und eher an klassische transaktionale Systeme erinnern.

Clustering und Gradient Boosting

Die Clusteranalyse der Chatprotokolle bestätigt, dass sich die Anfragen der Nutzenden in klar erkennbare Themenblöcke wie Ansprechpartner, Terminwünsche, Reklamationen und Begrüßungen gliedern lassen. Diese Strukturierung liefert wertvolle Hinweise darauf, welche Themen im System besonders prominent sind und wo sich die Einführung weiterer spezialisierter Prompts oder Flüsse, etwa für Terminvereinbarungen, am stärksten lohnt.

Demgegenüber bleibt der Gradient-Boosting-Ansatz bewusst explorativ, da die vorhandene Datenmenge für belastbare Prognosen nicht ausreicht. Die Implementierung zeigt jedoch, dass sich die technische Einbindung solcher Modelle problemlos realisieren lässt und bei wachsendem Datenvolumen perspektivisch genutzt werden könnte, um z.B. Nachfrage- oder Interessententendenzen modellhaft abzuschätzen, ohne dass dies den Kernfokus auf einen verlässlichen, erklärbaren Chatbot verwässert.

Einordnung im Kontext der Projektziele

Insgesamt bestätigt die Umsetzung, dass ein RAG-basierter Chatbot in der hier gewählten Architektur prinzipiell geeignet ist, quellenbasierte, nachvollziehbare Antworten für ein realitätsnahes Unternehmensszenario zu liefern. Zugleich zeigt die Arbeit sehr deutlich, dass eine produktive Integration ohne ergänzende organisatorische, rechtliche und qualitative Massnahmen – insbesondere hinsichtlich Datenpflege,

Monitoring und Umgang mit Fehlverhalten – nicht verantwortbar wäre, womit der Prototyp seinen Charakter als Demonstrator beibehält.

Die Erweiterungen um Clustering und erste Prognosemodelle unterstreichen schliesslich den Mehrwert, der aus der systematischen Auswertung von Chat- und Produktdaten entstehen kann, auch wenn die Modellgüte aktuell noch begrenzt ist. Dadurch wird die Projektarbeit über einen reinen „Chatbot-Prototypen“ hinaus zu einer integrierten Experimentierumgebung für datengetriebene Assistenzsysteme, in der sowohl technische als auch organisatorische Lernprozesse sichtbar werden.

Schlussfolgerungen

Bewertung des RAG-Chatbots

Die Projektarbeit zeigt, dass der entwickelte RAG-Chatbot in der gewählten Architektur grundsätzlich geeignet ist, quellenbasierte und nachvollziehbare Antworten zu liefern und Halluzinationen deutlich zu reduzieren. Guardrails mit expliziten Quellenangaben sowie die strikte Trennung zwischen modellinternem Wissen und Dokumenteninformation erhöhen die Transparenz und Überprüfbarkeit der Antworten für die Nutzenden. Gleichzeitig wird deutlich, dass die Leistungsfähigkeit des Systems stark von der Qualität und Konsistenz der Wissensbasis abhängt, was sich insbesondere in anfänglich fehlerhaften Ansprechpartner-Zuordnungen und unzureichend strukturierten Produktdaten zeigt.

Die Evaluation der Chunking-Strategien, des Retrieval-Verhaltens und der Dialogflüsse belegt, dass moderat grosse Chunk-Kontexte, robuste Retrieval-Ansätze und spezialisierte Prompt-Varianten – etwa für Reklamationen oder Bestellprozesse – entscheidend für stabile, kohärente und fachlich angemessene Antworten sind. Die iterative Verbesserung des Reklamations- und Bestellflusses verdeutlicht zudem, dass klar definierte Zustände, Slot-Filling und Validierung notwendig sind, um strukturierte Prozesse zuverlässig in einen freien Chatkontext einzubetten.

Einordnung im Projektkontext

Über den Chatbot hinaus zeigt die Arbeit, dass ergänzende analytische Komponenten wie Clustering-Verfahren wiederkehrende Nutzungsmuster sichtbar machen und damit gezielte Optimierungen der Wissensbasis und Dialoglogik ermöglichen. Die Experimente mit Gradient-Boosting-Modellen bleiben aufgrund der begrenzten Datenbasis bewusst explorativ, verdeutlichen aber, wie Chat- und Produktdaten für weiterführende Analysen technisch eingebunden werden können, ohne den Kernfokus auf einen robusten, erklärbaren Chatbot zu verändern.

Insgesamt wird deutlich, dass der RAG-Chatbot in der vorliegenden Form einen tragfähigen prototypischen Demonstrator für ein KI-gestütztes Assistenzsystem im Unternehmenskontext darstellt, eine produktive Einführung jedoch zusätzliche organisatorische, rechtliche und qualitative Absicherungen erfordern würde, insbesondere in Bezug auf Datenpflege, Monitoring und den Umgang mit Fehlverhalten.

Empfehlungen

Datenqualität

Es wird empfohlen, die Datenqualität der Wissensbasis gezielt zu erhöhen und laufend zu überwachen, da die Leistungsfähigkeit des RAG-Chatbots stark von konsistenten und korrekt strukturierten Daten abhängt. Die im Projekt beobachteten Probleme bei Ansprechpartner-Zuordnungen und Produktdaten machen deutlich, dass fehlerhafte oder verteilte Datenschemata die Nützlichkeit des Systems spürbar einschränken.

Empfehlung – Dialogflüsse und Usability

Es wird empfohlen, die bestehenden Dialogflüsse für Reklamationen und Bestellungen weiter auszubauen und um zusätzliche, klar definierte Flüsse zu ergänzen, zum Beispiel für Terminvereinbarungen mit dem Aussendienst oder strukturierte Produktberatung. Die in der Arbeit beschriebenen Erfahrungen mit Slot-Filling, Validierung und de-eskalierenden Reklamationsdialogen zeigen, dass sauber modellierte Abläufe Fehler reduzieren und das Nutzererlebnis deutlich verbessern.

Empfehlung – Monitoring und Fehlermanagement

Es sollte ein systematisches Monitoring eingerichtet werden, das Chats, Fehlersituationen und kritische Antworten fortlaufend erfasst, visualisiert und für Reviews bereitstellt. Auf dieser Basis können Richtlinien zum Umgang mit fehlerhaften Antworten definiert und Eskalationspfade festgelegt werden, sodass klar ist, wann der Chatbot an menschlichen Support übergibt und wie mit Risikofällen umzugehen ist.

Empfehlung – Ausbau analytischer Komponenten

Die bereits angelegte Clusteranalyse und der explorative Gradient-Boosting-Ansatz sollten weitergeführt werden, sobald mehr Daten vorliegen, um Nutzungsmuster und mögliche Nachfrage- oder Interessententendenzen gezielter auszuwerten. So kann der Chatbot nicht nur als Assistenzsystem, sondern auch als Datenquelle für kontinuierliche Verbesserung von Wissensbasis, Dialoglogik und Produktangebot genutzt werden.

Semantisch auf Themen prüfen

Die semantische Themenprüfung wird zu einem zentralen Steuerungsmechanismus ausgebaut, der jede eingehende Nachricht zuerst inhaltlich analysiert und einem vordefinierten Themencluster zuordnet, etwa Reklamationen, Bestellungen, Ansprechpartner, Terminwünsche, Produktberatung oder allgemeine Auskünfte. Grundlage dafür sind die bereits durchgeführte Clusteranalyse der Chatprotokolle und zusätzliche, feinere Cluster, die aus künftigen Chats gewonnen werden, sodass die Struktur der tatsächlichen Nutzung Schritt für Schritt abgebildet wird.

Für jedes dieser Cluster wird eine eigene, spezialisierte Systemnachricht definiert, die festlegt, wie der Chatbot in diesem Kontext sprechen soll, welche Rückfragen

zwingend zu stellen sind und welche Rahmenbedingungen gelten, zum Beispiel deeskalierende Formulierungen und strukturierte Fallaufnahme bei Reklamationen oder präzise Datenerfassung bei Bestellungen. Der bereits erfolgreich eingesetzte Reklamationsprompt dient dabei als Blaupause, um weitere cluster-spezifische Prompts zu entwickeln und so das Verhalten des Systems über mehrere Anwendungsfälle hinweg konsistent und fachlich angemessen zu steuern.

Im laufenden Betrieb wird jede gesendete Nachricht zunächst durch ein leichtgewichtiges Klassifikationsverfahren oder eine semantische Ähnlichkeitsprüfung einem Cluster zugeordnet, bevor der eigentliche Antwortprozess startet. Auf Basis dieses Clusterlabels wählt das System automatisch die passende Systemnachricht und erzeugt die Antwort immer im richtigen Kontext, sodass der Chatbot „weiss“, ob er gerade einen Reklamationsfall, eine Produktempfehlung, eine Terminfrage oder einen allgemeinen Informationswunsch bearbeitet.

Dieser Ansatz führt dazu, dass das System nicht mehr nur global mit einem einzigen Prompt arbeitet, sondern je nach Thema unterschiedliche Verhaltensregeln anwendet, was die in der Arbeit angestrebte Kombination aus quellenbasierten Antworten, Halluzinationsreduktion und kontrollierbarem Dialogverhalten weiter stärkt. Gleichzeitig schafft die enge Kopplung von Clusteranalyse und Prompt-Steuerung eine Grundlage, um neue, häufig auftretende Themenbereiche künftig schnell zu identifizieren, eigene Cluster dafür anzulegen und mit zusätzlichen spezialisierten Systemprompts zu ergänzen.

Rank Fusion

Für das Retrieval-Modul wird empfohlen, eine Rank-Fusion-Strategie einzuführen, die die Stärken der bereits vorhandenen lexikalischen und semantischen Suche gezielt kombiniert. Aktuell werden TF-IDF/BM25-ähnliche Verfahren und Embeddings bereits parallel eingesetzt; durch eine explizite Fusion der jeweiligen Ranglisten kann die Relevanz der ausgewählten Chunks weiter gesteigert und die Robustheit gegenüber Ausreißern einzelner Verfahren erhöht werden.

Konkret soll jede Nutzeranfrage parallel über beide Suchkanäle laufen: einerseits über die lexikalische Suche, die vor allem bei exakten Begriffen, Artikelnummern oder formalen Ausdrücken stark ist, andererseits über die semantische Suche, die Bedeutungsähnlichkeiten auch bei freier Formulierung oder synonymen Begriffen erfassen kann. Die beiden Ergebnislisten werden anschliessend durch ein Rank-Fusion-Verfahren (z.B. gewichtetes Kombinieren der Rangpositionen oder Scores) zu einer gemeinsamen Rangliste zusammengeführt, in der Dokumente oder Chunks bevorzugt werden, die in beiden Welten hoch eingestuft sind.

Auf diese Weise erhält der Chatbot eine konsolidierte, qualitativ höherwertige Kandidatenmenge, bevor die Antwortgenerierung startet, was direkt an die in der Arbeit hervorgehobene Abhängigkeit der Antwortqualität von Retrieval, Chunking und Datenqualität anknüpft. Durch die Kombination von Rank Fusion mit den bestehenden Guardrails und der strikten Trennung zwischen modellinternem Wissen und Wissensbasis

kann das System quellenbasierte, nachvollziehbare Antworten liefern und Halluzinationen weiter reduzieren, ohne sich einseitig auf ein einzelnes Retrieval-Verfahren zu stützen.

Referenzen Biographie


- A Guide to The Gradient Boosting Algorithm.* (o. J.). Abgerufen 23. Dezember 2025, von <https://www.datacamp.com/tutorial/guide-to-the-gradient-boosting-algorithm>
- Ertel, W. (2021). *Grundkurs Künstliche Intelligenz: Eine praxisorientierte Einführung*. Springer Fachmedien Wiesbaden. <https://doi.org/10.1007/978-3-658-32075-1>
- Forecasting with XGBoost and LightGBM - Skforecast Docs.* (o. J.). Abgerufen 23. Dezember 2025, von https://skforecast.org/0.13.0/user_guides/forecasting-xgboost-lightgbm
- Gradient Boosting Algorithm in Machine Learning: The Power of Combining Weak Models.* (2025, September 29). <https://deepfa.ir/en/blog/gradient-boosting-machine-learning-algorithm>
- GradientBoostingRegressor.* (o. J.). Scikit-Learn. Abgerufen 23. Dezember 2025, von <https://scikit-learn/stable/modules/generated/sklearn.ensemble.GradientBoostingRegressor.html>
- Poole, D. L., & Mackworth, A. K. (2023). *Artificial Intelligence: Foundations of Computational Agents* (3. Aufl.). Cambridge University Press. <https://doi.org/10.1017/9781009258227>
- Russell, S. J., & Norvig, P. (2023). *Künstliche Intelligenz: Ein moderner Ansatz* (4., aktualisierte Auflage). Pearson.
- Schmid, T., Hildesheim, W., & Holoyad, T. (2023). *Künstliche Intelligenz managen und verstehen: Der Praxis-Wegweiser für Entscheidungsträger, Entwickler und Regulierer* (1. Auflage). Beuth.
- Tunguz, B. (2025, Januar 20). *XGBoost is All You Need, Part 3—Gradient Boosted Trees.* <https://www.xgblog.ai/p/xgboost-is-all-you-need-part-3-gradient>

What is Gradient Boosting? | IBM. (2025, April 7). <https://www.ibm.com/think/topics/gradient-boosting>



Nutex Plus HSS, Standardausführung TiAlN-beschichtet

6155



Nutex Plus

Artikel Nr.	d1 mm	b mm	b1 mm		Nutttiefe mm	d2 mm	d3 mm	Aufnahme 6058.
6155.0568	50	2	2.73	30 BS	10.0 (5.0*)	16	28	.0430, .0530, .0630
6155.0569	50	2	2.73	20 BS	10.0	16	28	.0430, .0530, .0630
6155.0570	50	2.5	2.73	30 BS	10.5 (5.0*)	16	28	.0430, .0530, .0630
6155.0571	50	2.5	2.73	20 BS	10.5	16	28	.0430, .0530, .0630
6155.0572	50	3	3.08	30 BS	10.5 (5.0*)	16	28	.0430, .0530, .0630
6155.0573	50	3	3.08	20 BS	10.5	16	28	.0430, .0530, .0630
6155.0574	50	4	4.08	30 BS	10.5 (5.0*)	16	28	.0430, .0530, .0630
6155.0575	50	4	4.08	20 BS	10.5	16	28	.0430, .0530, .0630
6155.0576	50	5	5.08	30 BS	10.5 (5.0*)	16	28	.0430, .0530, .0630
6155.0577	50	5	5.08	20 BS	10.5	16	28	.0430, .0530, .0630
6155.0579	50	6	6.08	20 BS	10.5	16	28	.0430, .0530, .0630
6155.0628	63	2	2.73	26 BS	14.5 (7.5*)	16	32	.0440, .0540, .0640
6155.0629	63	2	2.73	18 BS	14.5	16	32	.0440, .0540, .0640
6155.0630	63	2.5	2.73	26 BS	15.0 (7.5*)	16	32	.0440, .0540, .0640
6155.0631	63	2.5	2.73	18 BS	15.0	16	32	.0440, .0540, .0640
6155.0632	63	3	3.08	26 BS	15.0 (7.5*)	16	32	.0440, .0540, .0640
6155.0633	63	3	3.08	18 BS	15.0	16	32	.0440, .0540, .0640
6155.0634	63	4	4.08	26 BS	15.0 (7.5*)	16	32	.0440, .0540, .0640
6155.0635	63	4	4.08	18 BS	15.0	16	32	.0440, .0540, .0640
6155.0636	63	5	5.08	26 BS	15.0 (7.5*)	16	32	.0440, .0540, .0640
6155.0637	63	5	5.08	18 BS	15.0	16	32	.0440, .0540, .0640
6155.0639	63	6	6.08	18 BS	15.0	16	32	.0440, .0540, .0640
6155.0658	80	2	2.73	24 BS	23.0 (11.5*)	16	32	.0440, .0540, .0640
6155.0659	80	2	2.73	16 BS	23.0	16	32	.0440, .0540, .0640
6155.0660	80	2.5	2.73	24 BS	23.5 (11.5*)	16	32	.0440, .0540, .0640
6155.0661	80	2.5	2.73	16 BS	23.5	16	32	.0440, .0540, .0640
6155.0662	80	3	3.08	24 BS	23.5 (11.5*)	16	32	.0440, .0540, .0640
6155.0663	80	3	3.08	16 BS	23.5	16	32	.0440, .0540, .0640
6155.0664	80	4	4.08	24 BS	23.5 (11.5*)	16	32	.0440, .0540, .0640
6155.0665	80	4	4.08	16 BS	23.5	16	32	.0440, .0540, .0640
6155.0666	80	5	5.08	24 BS	23.5 (11.5*)	16	32	.0440, .0540, .0640
6155.0667	80	5	5.08	16 BS	23.5	16	32	.0440, .0540, .0640
6155.0669	80	6	6.08	16 BS	23.5	16	32	.0440, .0540, .0640
6155.0718	100	2	2.73	24 BS	29.0 (14.5*)	22	40	.0650
6155.0719	100	2	2.73	16 BS	29.0	22	40	.0650
6155.0720	100	2.5	2.73	24 BS	29.5 (14.5*)	22	40	.0650
6155.0721	100	2.5	2.73	16 BS	29.5	22	40	.0650
6155.0722	100	3	3.08	24 BS	29.5 (14.5*)	22	40	.0650
6155.0723	100	3	3.08	16 BS	29.5	22	40	.0650
6155.0724	100	4	4.08	24 BS	29.5 (14.5*)	22	40	.0650
6155.0725	100	4	4.08	16 BS	29.5	22	40	.0650
6155.0726	100	5	5.08	24 BS	29.5 (14.5*)	22	40	.0650
6155.0727	100	5	5.08	16 BS	29.5	22	40	.0650
6155.0729	100	6	6.08	16 BS	29.5	22	40	.0650
6155.0748	125	2	2.73	24 BS	41.5 (21.0*)	22	40	.0650
6155.0749	125	2	2.73	16 BS	41.5	22	40	.0650
6155.0750	125	2.5	2.73	24 BS	42.0 (21.0*)	22	40	.0650
6155.0751	125	2.5	2.73	16 BS	42.0	22	40	.0650
6155.0752	125	3	3.08	24 BS	42.0 (21.0*)	22	40	.0650
6155.0753	125	3	3.08	16 BS	42.0	22	40	.0650
6155.0754	125	4	4.08	24 BS	42.0 (21.0*)	22	40	.0650
6155.0755	125	4	4.08	16 BS	42.0	22	40	.0650
6155.0756	125	5	5.08	24 BS	42.0 (21.0*)	22	40	.0650
6155.0757	125	5	5.08	16 BS	42.0	22	40	.0650
6155.0759	125	6	6.08	16 BS	42.0	22	40	.0650

* Empfohlene max. Tiefe beim Nutfräsen mit grosser Zähnezahl.



Alle Nutex Plus Sägen sind ab Lager lieferbar!



Angabe Nutttiefen gelten für Neuwerkzeuge. Pro Nachschärfen verringern sich diese im Schnitt um 0.5 mm.

	A	B	C	D	E	F	G	H	
1	Artikel Nr.,Beschichtung,d1 mm,b mm,b1 mm,Nuttiefe mm,Typ (Modell),d2 mm,d3 mm,Aufnahme 6058. _ _ _ _								
2	61550568,TiAlN-beschichtet,50,2,2.73,10.0 (5.0*),30 BS,16,28,".0430, .0530, .0630"								
3	61550569,TiAlN-beschichtet,50,2,2.73,10.0,20 BS,16,28,".0430, .0530, .0630"								
4	61550570,TiAlN-beschichtet,50,2.5,2.73,10.5 (5.0*),30 BS,16,28,".0430, .0530, .0630"								
5	61550571,TiAlN-beschichtet,50,2.5,2.73,10.5,20 BS,16,28,".0430, .0530, .0630"								
6	61550572,TiAlN-beschichtet,50,3,3.08,10.5 (5.0*),30 BS,16,28,".0430, .0530, .0630"								
7	61550573,TiAlN-beschichtet,50,3,3.08,10.5,20 BS,16,28,".0430, .0530, .0630"								
8	61550574,TiAlN-beschichtet,50,4,4.08,10.5 (5.0*),30 BS,16,28,".0430, .0530, .0630"								
9	61550575,TiAlN-beschichtet,50,4,4.08,10.5,20 BS,16,28,".0430, .0530, .0630"								
10	61550576,TiAlN-beschichtet,50,5,5.08,10.5 (5.0*),30 BS,16,28,".0430, .0530, .0630"								
11	61550577,TiAlN-beschichtet,50,5,5.08,10.5,20 BS,16,28,".0430, .0530, .0630"								
12	61550579,TiAlN-beschichtet,50,6,6.08,10.5,20 BS,16,28,".0430, .0530, .0630"								
13	61550628,TiAlN-beschichtet,63,2,2.73,14.5 (7.5*),26 BS,16,32,".0440, .0540, .0640"								
14	61550629,TiAlN-beschichtet,63,2,2.73,14.5,18 BS,16,32,".0440, .0540, .0640"								
15	61550630,TiAlN-beschichtet,63,2.5,2.73,15.0 (7.5*),26 BS,16,32,".0440, .0540, .0640"								
16	61550631,TiAlN-beschichtet,63,2.5,2.73,15.0,18 BS,16,32,".0440, .0540, .0640"								
17	61550632,TiAlN-beschichtet,63,3,3.08,15.0 (7.5*),26 BS,16,32,".0440, .0540, .0640"								
18	61550633,TiAlN-beschichtet,63,3,3.08,15.0,18 BS,16,32,".0440, .0540, .0640"								
19	61550634,TiAlN-beschichtet,63,4,4.08,15.0 (7.5*),26 BS,16,32,".0440, .0540, .0640"								
20	61550635,TiAlN-beschichtet,63,4,4.08,15.0,18 BS,16,32,".0440, .0540, .0640"								
21	61550636,TiAlN-beschichtet,63,5,5.08,15.0 (7.5*),26 BS,16,32,".0440, .0540, .0640"								
22	61550637,TiAlN-beschichtet,63,5,5.08,15.0,18 BS,16,32,".0440, .0540, .0640"								

Cluster 0

Top-Terme

wer geschäftsleitung in geschäftsleitung in wer mathia

Beispiele

- Hallo wer ist Mathias Senn?
- Wer ist Mathias Senn
- Also wer ist in der Geschäftsleitung?

Cluster 1

Top-Terme

hallo bin hallo bin hallo bins bins bin david davi

Beispiele

- hallo ich bins Luca
- Hallo ich bin Fabienne
- Hallo ich bin Germe

Cluster 2

Top-Terme

möchte gerne möchte gerne zu kommt aussendienstler dass ausse

Beispiele

- ich möchte dass jemand zu mir kommt
- ich habe ein Problem und möchte gerne dass jemand sich das anschauen kommt
- ich möchte gerne dass ein Aussendienstler zu mir kommt

Cluster 3

Top-Terme

moin okay es mindestbestellwert was nach kannst einen tagen

Beispiele

- an wenn soll ich die fotos senden?
- ich habe vor 12 tagen ein Nutex erhalten und jetzt gesehen, dass es nicht ganz richti
- Hallo ich habe grade gesehen dass die ware die ich vor 10 tagen erhalten habe, feler

Eigenständigkeitserklärung

Ich erkläre hiermit,

- dass ich den vorliegenden Leistungsnachweis selbst und selbständig verfasst habe;
- dass ich sämtliche nicht von mir selbst stammenden Textstellen gemäss gängigen wissenschaftlichen Zitierregeln korrekt zitiert und die verwendeten Quellen gut sichtbar erwähnt habe;
- dass ich sämtliche immateriellen Rechte an von mir allfällig verwendeten Materialien wie Bildern oder Grafiken erworben habe oder dass diese Materialien von mir selbst erstellt wurden;
- dass das Thema, die Arbeit oder Teile davon nicht bei einem Leistungsnachweis eines anderen Moduls verwendet wurden, sofern dies nicht ausdrücklich mit der Dozentin oder dem Dozenten im Voraus vereinbart wurde und in der Arbeit ausgewiesen wird;
- dass ich mir bewusst bin, dass meine Arbeit auf Plagiate und auf Drittautorschaft menschlichen oder technischen Ursprungs (künstliche Intelligenz) überprüft werden kann;
- dass ich mir bewusst bin, dass die Hochschule für Wirtschaft FHNW einen Verstoss gegen diese Eigenständigkeitserklärung bzw. die ihr zugrundeliegenden Pflichten der Studien- und Prüfungsordnung der Hochschule für Wirtschaft FHNW verfolgt. Zu den Pflichten gehört insbesondere die Wahrung von Urheberrechten und das Unterlassen von Plagiaten (§ 29 Abs. 1 lit. d StuPO). Ein diesbezüglicher Verstoss wird mit der Note 1 bewertet und es können zusätzlich disziplinarische Folgen (Verweis/Ausschluss aus dem Studiengang) resultieren.

David Germann

Sarmenstorf, 29.12.2025



Reproduzierbarkeit

Der Quellcode zum Prototyp ist im folgenden Repository verfügbar auf GitHub ([Germe-03/ALESA Chatbot](#)). Die Konfiguration erfolgt über Umgebungsvariablen (z. B. .env/.env.example); sensible Werte wie API-Keys sind nicht im Repository enthalten. Abhängigkeiten sind im Projekt mitgeführt (z. B. requirements.txt/pyproject.toml), so dass der Implementierungsstand damit grundsätzlich nachvollzogen werden kann.